UBND THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC SÀI GÒN

----□☯□----



BÁO CÁO MÔN HỌC

Tên đề tài : BT4_Rule_kNN_Bayes

Học phần : Máy học

Tên sinh viên : Lê Văn Phong

MSSV : 3124411227

PHẦN 1. CÂY QUYẾT ĐỊNH

Câu 1. Cây quyết định cho tập dữ liệu mùa

Tập có 12 mẫu, thuộc tính Thời tiết, Lá cây, Nhiệt độ, nhãn là Mùa. Ký hiệu T = Thu, Đ = Đông, X = Xuân, H = Hè; số đứng trước là số thứ tự mẫu (ví dụ 7Đ là mẫu 7 mùa Đông).

a) Xây dựng cây bằng ID3

Tập gốc có 3 Thu (1, 4, 10), 5 Đông (2, 3, 5, 6, 7), 2 Xuân (8, 12), 2 Hè (9, 11) nên:

H(S) = −(3/12)log2(3/12) − (5/12)log2(5/12) − 2×(2/12)log2(2/12) = 0.5000 + 0.5263 + 0.8617 = 1.8879

Thuộc tính Thời tiết

Nắng (1T, 7Đ, 8X, 9H): mỗi mùa 1 mẫu, H = 2.0

Tuyết (2Đ, 3Đ, 6Đ): toàn Đông, H = 0

Mưa (4T, 5Đ, 10T, 11H, 12X): 2T, 1Đ, 1H, 1X, H = 1.9219

Entropy(Thời tiết) = 4/12×2.0 + 3/12×0 + 5/12×1.9219 = 1.4675

IG(Thời tiết) = 1.8879 − 1.4675 = 0.4204

Thuộc tính Lá cây

Vàng (1T, 3Đ, 4T): 2T, 1Đ, H = 0.9183

Xanh (2Đ, 8X, 9H, 11H, 12X): 1Đ, 2X, 2H, H = 1.5219

Rụng (5Đ, 6Đ, 7Đ, 10T): 3Đ, 1T, H = 0.8113

Entropy(Lá cây) = 3/12×0.9183 + 5/12×1.5219 + 4/12×0.8113 = 1.1341

IG(Lá cây) = 1.8879 − 1.1341 = 0.7538

Thuộc tính Nhiệt độ

Trung bình (1T, 4T, 8X, 10T, 12X): 3T, 2X, H = 0.9710

Thấp (2Đ, 3Đ, 5Đ, 6Đ, 7Đ): toàn Đông, H = 0

Cao (9H, 11H): toàn Hè, H = 0

Entropy(Nhiệt độ) = 5/12×0.9710 + 5/12×0 + 2/12×0 = 0.4046

IG(Nhiệt độ) = 1.8879 − 0.4046 = 1.4833

Nhiệt độ có Entropy trung bình thấp nhất (IG lớn nhất) nên chọn làm nút gốc. Nhánh Cao toàn Hè, nhánh Thấp toàn Đông nên dừng. Nhánh Trung bình còn 5 mẫu (1T, 4T, 8X, 10T, 12X) có Entropy 0.9710, cần tách tiếp.

Tại nhánh Nhiệt độ = Trung bình:

Thời tiết: Nắng (1T, 8X) H = 1.0; Mưa (4T, 10T, 12X) H = 0.9183. Entropy = 2/5×1.0 + 3/5×0.9183 = 0.9510

Lá cây: Vàng (1T, 4T), Xanh (8X, 12X), Rụng (10T) đều thuần nhất nên Entropy = 0

Chọn Lá cây vì có Entropy thấp nhất.

Cây quyết định:

Nhiệt độ = Cao: Hè

Nhiệt độ = Thấp: Đông

Nhiệt độ = Trung bình: xét Lá cây

Lá cây = Vàng: Thu

Lá cây = Xanh: Xuân

Lá cây = Rụng: Thu

Bộ luật:

Luật 1: Nếu Nhiệt độ = Cao thì Mùa = Hè

Luật 2: Nếu Nhiệt độ = Thấp thì Mùa = Đông

Luật 3: Nếu Nhiệt độ = Trung bình và Lá cây = Xanh thì Mùa = Xuân

Luật 4: Nếu Nhiệt độ = Trung bình và Lá cây = Vàng hoặc Rụng thì Mùa = Thu

b) Phân lớp mẫu X và Y

X = (Mưa, Vàng, Thấp): Nhiệt độ = Thấp nên áp dụng luật 2, Mùa = Đông.

Y = (Tuyết, Rụng, Trung bình): Nhiệt độ = Trung bình và Lá cây = Rụng nên áp dụng luật 4, Mùa = Thu.

c) Cây dùng Gini và lỗi phân lớp

Công thức: Gini = $1 - \Sigma p_i^2$, lỗi phân lớp = $1 - \max p_i$. Ở tập gốc: Gini(S) = $1 - (3/12)^2 - (5/12)^2 - 2\times(2/12)^2 = 0.7083$; lỗi(S) = $1 - 5/12 = 0.5833$.

Gini từng nhánh:

Thời tiết: Nắng 0.75, Tuyết 0, Mưa 0.72. Gini TB = 4/12×0.75 + 5/12×0.72 = 0.5500

Lá cây: Vàng 0.4444, Xanh 0.64, Rụng 0.375. Gini TB = 3/12×0.4444 + 5/12×0.64 + 4/12×0.375 = 0.5028

Nhiệt độ: Trung bình 0.48, Thấp 0, Cao 0. Gini TB = 5/12×0.48 = 0.2000

Lỗi phân lớp từng nhánh:

Thời tiết: Nắng 0.75, Tuyết 0, Mưa 0.6. Lỗi TB = 4/12×0.75 + 5/12×0.6 = 0.5000

Lá cây: Vàng 0.3333, Xanh 0.6, Rụng 0.25. Lỗi TB = 3/12×0.3333 + 5/12×0.6 + 4/12×0.25 = 0.4167

Nhiệt độ: Trung bình 0.4. Lỗi TB = 5/12×0.4 = 0.1667

Thuộc tính	Entropy TB	Gini TB	Lỗi TB
Thời tiết	1.4675	0.5500	0.5000
Lá cây	1.1341	0.5028	0.4167
Nhiệt độ	0.4046	0.2000	0.1667

Cả ba độ đo đều nhỏ nhất ở Nhiệt độ nên đều chọn làm gốc. Ở nhánh Trung bình, Lá cây cho các nhóm thuần nhất (độ đo bằng 0) trong khi Thời tiết thì không (Gini 0.4667, lỗi 0.4), nên cũng chọn Lá cây. Vậy cây giống hệt cây ID3, X vẫn là Đông và Y vẫn là Thu.

Câu 2. Cây quyết định cho tập dữ liệu lá cây độc

Tập huấn luyện gồm mẫu 1 đến 10, có 6 Có (2, 5, 6, 8, 9, 10) và 4 Không (1, 3, 4, 7). Ký hiệu C = Có, K = Không.

d) Cây dùng Gini

Gini(S) = $1 - 0.6^2 - 0.4^2 = 0.48$

Hình dạng: Tròn (1K, 2C, 3K, 7K, 8C, 9C) có 3C 3K, Gini = 0.5; Dài (4K, 5C, 6C, 10C) có 3C 1K, Gini = 0.375. Gini TB = 6/10×0.5 + 4/10×0.375 = 0.45

Dạng: Đơn (1K, 3K, 4K, 6C, 9C, 10C) có 3C 3K, Gini = 0.5; Kép (2C, 5C, 7K, 8C) có 3C 1K, Gini = 0.375. Gini TB = 6/10×0.5 + 4/10×0.375 = 0.45

Màu: Đỏ (1K, 2C, 9C, 10C) có 3C 1K, Gini = 0.375; Xanh (3K, 4K, 6C) có 1C 2K, Gini = 0.4444; Vàng (5C, 7K, 8C) có 2C 1K, Gini = 0.4444. Gini TB = 4/10×0.375 + 3/10×0.4444 + 3/10×0.4444 = 0.4167

Kích thước: Nhỏ (1K, 2C, 4K, 5C) có 2C 2K, Gini = 0.5; Vừa (6C, 8C, 9C, 10C) toàn Có, Gini = 0; To (3K, 7K) toàn Không, Gini = 0. Gini TB = 4/10×0.5 = 0.2

Kích thước có Gini nhỏ nhất nên chọn làm gốc. Nhánh Vừa toàn Có, nhánh To toàn Không. Nhánh Nhỏ còn 4 mẫu: 1 (Tròn, Đơn, Đỏ, K), 2 (Tròn, Kép, Đỏ, C), 4 (Dài, Đơn, Xanh, K), 5 (Dài, Kép, Vàng, C), Gini = 0.5. Tách tiếp:

Hình dạng: Tròn (1K, 2C) 0.5, Dài (4K, 5C) 0.5. Gini TB = 0.5

Dạng: Đơn (1K, 4K) toàn Không, Kép (2C, 5C) toàn Có. Gini TB = 0

Màu: Đỏ (1K, 2C) 0.5, Xanh 0, Vàng 0. Gini TB = 2/4×0.5 = 0.25

Chọn Dạng vì Gini TB bằng 0.

Cây quyết định:

Kích thước = Vừa: Có

Kích thước = To: Không

Kích thước = Nhỏ: xét Dạng

Dạng = Đơn: Không

Dạng = Kép: Có

e) Phân lớp mẫu 11 và 12

Mẫu 11 = (Dài, Kép, Đỏ, Vừa): Kích thước = Vừa nên Độc = Có.

Mẫu 12 = (Tròn, Đơn, Xanh, Nhỏ): Kích thước = Nhỏ, Dạng = Đơn nên Độc = Không.

f) Cây dùng Entropy và lỗi phân lớp

Entropy(S) = −0.6×log2(0.6) − 0.4×log2(0.4) = 0.9710; lỗi(S) = 1 − 0.6 = 0.4. Kết quả cho từng thuộc tính ở tập gốc:

Thuộc tính	Entropy TB	IG	Lỗi TB
Hình dạng	0.9245	0.0465	0.4000
Dạng	0.9245	0.0465	0.4000
Màu	0.8755	0.0955	0.3000
Kích thước	0.4000	0.5710	0.2000

Kích thước có Entropy và lỗi nhỏ nhất, giống kết quả của Gini nên vẫn là gốc. Ở nhánh Nhỏ (Entropy 1.0, lỗi 0.5), Dạng cho Entropy TB = 0 và lỗi TB = 0, còn Hình dạng vẫn là 1.0 và 0.5, Màu là 0.5 và 0.25. Nên vẫn tách theo Dạng, cây không đổi, mẫu 11 là Có và mẫu 12 là Không.

Câu 3. Cây quyết định cho dữ liệu quyết định

Tập huấn luyện mẫu 1 đến 10, có 6 Có (2, 3, 4, 6, 7, 10) và 4 Không (1, 5, 8, 9). Ký hiệu C = Có, K = Không.

a) Cây dùng lỗi phân lớp

Lỗi(S) = 1 − 6/10 = 0.4

Phái: Nam (1K, 4C, 5K, 6C, 7C, 9K) lỗi = 1 − 3/6 = 0.5; Nữ (2C, 3C, 8K, 10C) lỗi = 1 − 3/4 = 0.25. Lỗi TB = 6/10×0.5 + 4/10×0.25 = 0.4

Công việc: Chân tay (1K, 3C, 5K, 7C, 8K, 10C) lỗi = 0.5; Trí óc (2C, 4C, 6C, 9K) lỗi = 0.25. Lỗi TB = 6/10×0.5 + 4/10×0.25 = 0.4

Học vấn: Cao đẳng (1K, 4C, 7C, 10C) lỗi = 0.25; Đại học (2C, 6C, 9K) lỗi = 0.3333; Phổ thông (3C, 5K, 8K) lỗi = 0.3333. Lỗi TB = 4/10×0.25 + 3/10×0.3333 + 3/10×0.3333 = 0.3

Độ tuổi: Trung niên (1K, 2C, 4C, 8K) lỗi = 0.5; Già (3C, 6C, 7C, 10C) lỗi = 0; Thanh niên (5K, 9K) lỗi = 0. Lỗi TB = 4/10×0.5 = 0.2

Độ tuổi có lỗi nhỏ nhất nên chọn làm gốc. Nhánh Già toàn Có, nhánh Thanh niên toàn Không. Nhánh Trung niên còn 4 mẫu (1K, 2C, 4C, 8K), lỗi = 0.5. Tách tiếp:

Phái: Nam (1K, 4C) 0.5, Nữ (2C, 8K) 0.5. Lỗi TB = 0.5

Công việc: Chân tay (1K, 8K) toàn Không, Trí óc (2C, 4C) toàn Có. Lỗi TB = 0

Học vấn: Cao đẳng (1K, 4C) 0.5, Đại học (2C) 0, Phổ thông (8K) 0. Lỗi TB = 2/4×0.5 = 0.25

Chọn Công việc vì lỗi TB bằng 0.

Cây quyết định:

Độ tuổi = Già: Có

Độ tuổi = Thanh niên: Không

Độ tuổi = Trung niên: xét Công việc

Công việc = Trí óc: Có

Công việc = Chân tay: Không

b) Phân lớp mẫu A và B

A = (Nữ, Trí óc, Cao đẳng, Già): Độ tuổi = Già nên Quyết định = Có.

B = (Nam, Chân tay, Phổ thông, Trung niên): Độ tuổi = Trung niên, Công việc = Chân tay nên Quyết định = Không.

c) So sánh với Gini và Entropy

Gini(S) = 0.48; Entropy(S) = 0.9710. Kết quả ở tập gốc:

Thuộc tính	Gini TB	Entropy TB	IG	Lỗi TB
Phái	0.4500	0.9245	0.0465	0.4000
Công việc	0.4500	0.9245	0.0465	0.4000
Học vấn	0.4167	0.8755	0.0955	0.3000
Độ tuổi	0.2000	0.4000	0.5710	0.2000

Cả ba độ đo đều chọn Độ tuổi làm gốc. Ở nhánh Trung niên, Công việc có Gini, Entropy, lỗi đều bằng 0 (Phái là 0.5, 1.0, 0.5; Học vấn là 0.25, 0.5, 0.25) nên cả ba cũng chọn Công việc. Vậy cây giống nhau và A là Có, B là Không.

PHẦN 2. PHÂN LỚP NAIVE BAYES

Naive Bayes giả sử các thuộc tính độc lập với nhau khi đã biết lớp nên: P(lớp | x) tỉ lệ với P(lớp) × tích các $P(x_i \mid \text{lớp})$.

Câu 1. Dữ liệu chơi ngoài trời (thuộc tính rời rạc)

a) Tính Prior và Likelihood

Tập có 14 mẫu: 9 Yes và 5 No.

Prior: P(Yes) = 9/14 = 0.6429; P(No) = 5/14 = 0.3571.

Likelihood = số mẫu của lớp có giá trị đó / số mẫu của lớp (Yes có 9 mẫu, No có 5 mẫu):

Thuộc tính = giá trị	P(. | Yes)	P(. | No)
Outlook = Sunny	2/9 = 0.2222	3/5 = 0.6000
Outlook = Overcast	4/9 = 0.4444	0/5 = 0
Outlook = Rainy	3/9 = 0.3333	2/5 = 0.4000
Temp = Hot	2/9 = 0.2222	2/5 = 0.4000
Temp = Mild	4/9 = 0.4444	2/5 = 0.4000
Temp = Cool	3/9 = 0.3333	1/5 = 0.2000
Humidity = High	3/9 = 0.3333	4/5 = 0.8000
Humidity = Normal	6/9 = 0.6667	1/5 = 0.2000
Windy = False	6/9 = 0.6667	2/5 = 0.4000
Windy = True	3/9 = 0.3333	3/5 = 0.6000

Ghi chú: Overcast với lớp No bằng 0. Mẫu cần phân lớp bên dưới không có Overcast nên không cần làm trơn Laplace.

b) Phân lớp mẫu (Sunny, Cool, High, True)

Yes: 9/14 × 2/9 × 3/9 × 3/9 × 3/9 = 0.0053

No: 5/14 × 3/5 × 1/5 × 4/5 × 3/5 = 0.0206

Chuẩn hóa: P(Yes) = 0.0053/(0.0053 + 0.0206) = 0.2046; P(No) = 0.7954

Điểm của No lớn hơn nên mẫu thuộc lớp No (không chơi).

c) Phân lớp khi dữ liệu bị nhiễu (thiếu Outlook)

Mẫu (?, Cool, High, True) bị mất Outlook. Cách làm là bỏ Outlook ra khỏi tích, chỉ nhân các thuộc tính còn lại:

Yes: 9/14 × 3/9 × 3/9 × 3/9 = 0.0238

No: 5/14 × 1/5 × 4/5 × 3/5 = 0.0343

Chuẩn hóa: P(Yes) = 0.4098; P(No) = 0.5902

Kết quả vẫn là No nhưng độ chắc chắn giảm (59% so với 80% khi có Outlook), vì Sunny là thông tin nghiêng mạnh về No.

Câu 2. Dữ liệu có thuộc tính số (Temperature, Humidity)

a) Tính Prior và Likelihood

Tập có 14 mẫu: 9 yes và 5 no. Prior: P(yes) = 9/14 = 0.6429; P(no) = 5/14 = 0.3571.

Outlook và Windy là thuộc tính rời rạc, tính bằng tỉ lệ như câu 1:

Thuộc tính = giá trị	P(. | yes)	P(. | no)
Outlook = sunny	2/9 = 0.2222	3/5 = 0.6000
Outlook = overcast	4/9 = 0.4444	0/5 = 0
Outlook = rain	3/9 = 0.3333	2/5 = 0.4000
Windy = false	6/9 = 0.6667	2/5 = 0.4000
Windy = true	3/9 = 0.3333	3/5 = 0.6000

Temperature và Humidity là thuộc tính số nên giả sử phân phối chuẩn, tính trung bình μ và độ lệch chuẩn s (chia cho $n - 1$) theo từng lớp, sau đó dùng $f(x) = 1/(s\sqrt{(2\pi)}) \times \exp(-(x - \mu)^2/(2s^2))$:

Thuộc tính	Lớp	μ	s
Temperature	yes	73.0000	6.1644
Temperature	no	74.6000	7.8930
Humidity	yes	78.2222	9.8841
Humidity	no	84.0000	9.6177

b) Phân lớp mẫu (sunny, 66, 90, true)

Lớp	f(66 | Temperature)	f(90 | Humidity)
yes	0.03396	0.01984
no	0.02792	0.03415

yes: 9/14 × 2/9 × 0.03396 × 0.01984 × 3/9 = 0.0000321

no: 5/14 × 3/5 × 0.02792 × 0.03415 × 3/5 = 0.0001226

Chuẩn hóa: P(yes) = 0.2075; P(no) = 0.7925

Điểm của no lớn hơn nên mẫu thuộc lớp no.

Câu 3. Phân loại email Spam

Từ vựng gồm 7 từ w1 đến w7. Huấn luyện có E1, E2 (Not Spam, N) và E3 (Spam, S).

a) Tính Prior và Likelihood

Prior: P(N) = 2/3 = 0.6667; P(S) = 1/3 = 0.3333.

Đếm số lần mỗi từ xuất hiện trong từng lớp (cộng các email cùng lớp):

Lớp	w1	w2	w3	w4	w5	w6	w7	Tổng
N (E1 + E2)	1	4	1	0	2	1	1	10
S (E3)	1	0	1	1	0	2	0	5

Có từ xuất hiện 0 lần (ví dụ w7 trong lớp S) sẽ làm cả tích bằng 0, nên dùng làm trơn Laplace với |V| = 7:

P(w | lớp) = (số lần w trong lớp + 1) / (tổng số từ của lớp + 7)

Mẫu số của N là 10 + 7 = 17, của S là 5 + 7 = 12.

Từ	P(. | N)	P(. | S)
w1	2/17 = 0.1176	2/12 = 0.1667
w2	5/17 = 0.2941	1/12 = 0.0833
w3	2/17 = 0.1176	2/12 = 0.1667
w4	1/17 = 0.0588	2/12 = 0.1667
w5	3/17 = 0.1765	1/12 = 0.0833
w6	2/17 = 0.1176	3/12 = 0.2500
w7	2/17 = 0.1176	1/12 = 0.0833

b) Phân lớp E4

E4 có w1 xuất hiện 1 lần và w7 xuất hiện 1 lần, các từ khác bằng 0 nên chỉ nhân hai từ này:

N: 2/3 × (2/17) × (2/17) = 0.00923

S: 1/3 × (2/12) × (1/12) = 0.00463

Điểm của N lớn hơn nên E4 là Not Spam. Nếu không làm trơn thì điểm của S bằng 0 (vì w7 chưa từng xuất hiện trong S) còn N là 2/3 × 1/10 × 1/10 = 0.0067, kết quả vẫn là N.

PHẦN 3. HỌC DỰA TRÊN ĐỘ TƯƠNG TỰ (k-NN)

Câu 1. k-NN cơ bản

Mẫu cần phân lớp: (GPA, Assignment, Project) = (6.5, 55, 5). Khoảng cách Euclid: d = √((x − y)² + (x − y)² + (x − y)²). Ví dụ với mẫu 1: d = √((9 − 6.5)² + (88 − 55)² + (9 − 5)²) = √1111.25 = 33.3354.

STT	GPA	Assignment	Project	Khoảng cách d	Nhãn
1	9.0	88	9	33.3354	Pass
2	8.2	75	8	20.2951	Pass
3	6.0	45	5	10.0125	Fail
4	5.5	40	4	15.0665	Fail
5	7.8	70	7	15.1885	Pass
6	6.2	50	5	5.0090	Fail

Sắp xếp tăng dần: mẫu 6 (5.0090, Fail), mẫu 3 (10.0125, Fail), mẫu 4 (15.0665, Fail), mẫu 5 (15.1885, Pass), mẫu 2 (20.2951, Pass), mẫu 1 (33.3354, Pass).

k = 3: ba láng giềng gần nhất là mẫu 6, 3, 4 đều Fail, bỏ phiếu 3 Fail, 0 Pass nên nhãn là **Fail**.

k = 1: láng giềng gần nhất là mẫu 6 nên nhãn là Fail.

k = 5: gồm mẫu 6, 3, 4, 5, 2 được 3 Fail, 2 Pass nên nhãn là Fail.

Nhận xét: cả ba giá trị k đều ra Fail. Tuy nhiên Assignment có thang điểm lớn hơn nhiều (40 đến 88) so với GPA và Project (4 đến 9) nên khoảng cách gần như chỉ do Assignment quyết định, GPA và Project hầu như không đóng góp.

Câu 2. k-NN với chuẩn hóa dữ liệu

Đề không nêu k nên mình dùng k = 1 và k = 3. Mẫu test (172, 80).

1. k-NN trực tiếp (chưa chuẩn hóa)

Mẫu	Height	Weight	Lớp	Khoảng cách d
1	170	60	A	20.0998
2	175	65	A	15.2971
3	160	90	B	15.6205
4	158	85	B	14.8661

Thứ tự gần nhất: mẫu 4 (B), mẫu 2 (A), mẫu 3 (B), mẫu 1 (A). k = 1 cho lớp B. k = 3 gồm B, A, B nên cũng là lớp **B**.

2. Chuẩn hóa Min-Max

$x' = (x - \min)/(\max - \min)$. Height: min = 158, max = 175 (khoảng 17). Weight: min = 60, max = 90 (khoảng 30). Test: (14/17; 20/30) = (0.8235; 0.6667).

Mẫu	Height′	Weight′	Lớp	Khoảng cách d
1	0.7059	0.0000	A	0.6770
2	1.0000	0.1667	A	0.5302
3	0.1176	1.0000	B	0.7806
4	0.0000	0.8333	B	0.8402

3. k-NN sau chuẩn hóa

Thứ tự gần nhất: mẫu 2 (A), mẫu 1 (A), mẫu 3 (B), mẫu 4 (B). k = 1 cho lớp A, k = 3 gồm A, A, B nên là lớp **A**.

4. So sánh

Trước khi chuẩn hóa test thuộc lớp B, sau khi chuẩn hóa thì thành lớp A, nên kết quả bị đổi. Nguyên nhân: khi chưa chuẩn hóa, chênh lệch cân nặng (tới 20 kg) lớn hơn nhiều so với chiều cao (vài cm) nên khoảng cách chủ yếu do Weight quyết định, và Weight = 80 gần hai mẫu lớp B (85, 90) nên bị kéo về B. Sau khi chuẩn hóa, mỗi thuộc tính nằm trong khoảng 0 đến 1 và đóng góp ngang nhau, lúc đó Height = 172 rất gần lớp A (170, 175) nên kết quả chuyển về A. Vậy cần chuẩn hóa khi các thuộc tính có thang đo khác nhau.

Câu 3. k-NN có trọng số

Mẫu test (6, 6).

Mẫu	x1	x2	Lớp	Khoảng cách d
1	2	3	A	5.0000
2	3	4	A	3.6056
3	7	8	B	2.2361
4	8	9	B	3.6056
5	5	5	A	1.4142

Sắp xếp: mẫu 5 (1.4142), mẫu 3 (2.2361), rồi mẫu 2 và mẫu 4 cùng bằng 3.6056 (cùng $\sqrt{13}$), cuối cùng là mẫu 1. Với k = 3, hai mẫu 2 và 4 hòa nhau ở vị trí thứ 3. Mình chọn mẫu đứng trước trong bảng (mẫu 2).

Ba láng giềng: mẫu 5 (A), mẫu 3 (B), mẫu 2 (A). Trọng số 1/d: 0.7071; 0.4472; 0.2774, tổng = 1.4317. Trọng số chuẩn hóa: 0.4939; 0.3124; 0.1937.

Tổng trọng số lớp A = 0.4939 + 0.1937 = 0.6876

Tổng trọng số lớp B = 0.3124

Lớp dự đoán là **A**. Với k-NN thông thường: A, B, A nên bỏ phiếu cũng ra A, hai cách cho cùng kết quả (nhưng weighted cho thấy A thắng với độ tin cậy 69%). Lưu ý nếu chọn mẫu 4 thay cho mẫu 2 thì k-NN thường ra B (A, B, B) và weighted ra B nhẹ (0.5061 so với 0.4939), nên kết quả khá nhạy khi bị hòa.

Câu 4. Nearest Centroid

1. Tâm của từng lớp (trung bình tọa độ):

Lớp A: x = (2 + 3 + 4)/3 = 3; y = (1 + 2 + 1)/3 = 1.3333, tâm A = (3; 1.3333)

Lớp B: x = (7 + 8 + 9)/3 = 8; y = (6 + 7 + 5)/3 = 6, tâm B = (8; 6)

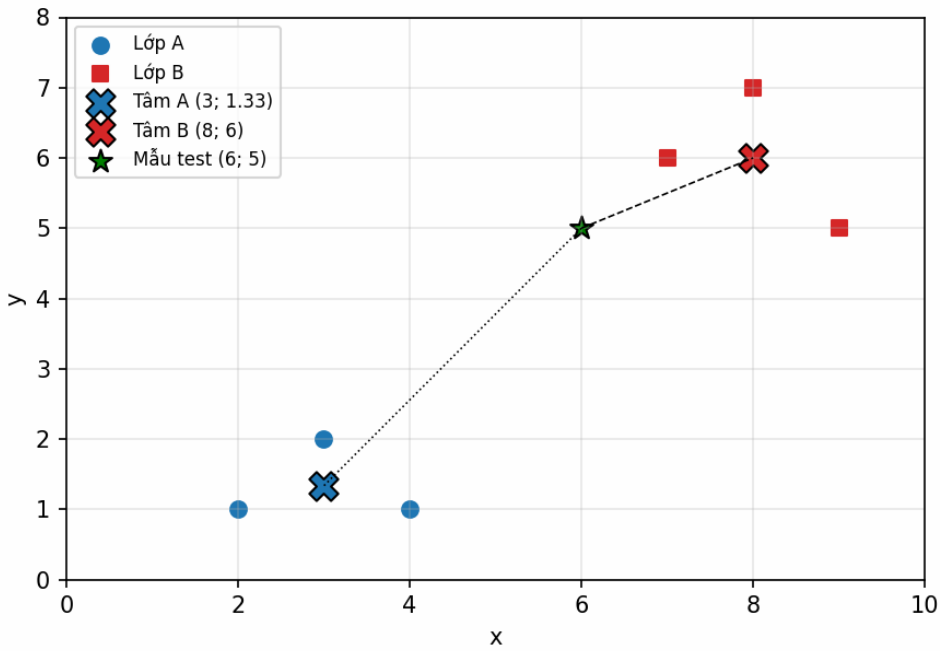
2. Khoảng cách từ test (6, 5) đến từng tâm:

$d(\text{test}, A) = \sqrt{((6-3)^2 + (5-1.3333)^2)} = \sqrt{22.4444} = 4.7376$

$d(\text{test}, B) = \sqrt{((6-8)^2 + (5-6)^2)} = \sqrt{5} = 2.2361$

3. Dự đoán: d đến tâm B nhỏ hơn nên test thuộc lớp **B**.

4. Biểu đồ:



Câu 5. Hồi quy trọng số cục bộ (LWR)

Mô hình $h(x) = 1 + 2x$, $\tau = 1$, điểm cần dự đoán $x = 2.5$.

1. Dự đoán: $h(2.5) = 1 + 2\times2.5 = 6$.

2 và 3. Khoảng cách và trọng số Gauss $w_i = \exp(-(x_i - x)^2/(2\tau^2))$:

x_i	y_i	$\lvert x_i - 2.5\rvert$	w_i
1	3	1.5	0.3247
2	5	0.5	0.8825
3	7	0.5	0.8825
4	9	1.5	0.3247

4. Hai điểm $x = 2$ và $x = 3$ có trọng số lớn nhất (0.8825) vì gần $x = 2.5$ nhất, nên ảnh hưởng nhiều nhất. Hai điểm $x = 1$ và $x = 4$ xa hơn nên trọng số chỉ 0.3247. Kiểm tra: trung bình có trọng số của y là $(0.3247\times3 + 0.8825\times5 + 0.8825\times7 + 0.3247\times9)/2.4144 = 6$, bằng với $h(2.5)$ vì các điểm nằm đúng trên đường $y = 2x + 1$.

Câu 6. Phân loại triệu chứng COVID bằng k-NN

1. Chuyển dữ liệu sang nhị phân

Có = 1, Không = 0. Thứ tự 9 triệu chứng: Sốt, Ho khan, Mệt mỏi, Đau họng, Tiêu chảy, Đau đầu, Mất vị giác/khứu giác, Khó thở, Đau ngực. Bệnh nhân mới có vector **111100000** (sốt, ho khan, mệt mỏi, đau họng).

2. Tính khoảng cách Hamming

Khoảng cách Hamming $d(x, y) = \Sigma|x_i - y_i|$ là số vị trí khác nhau giữa hai vector.

ID	Vector nhị phân	Vị trí khác	d	Kết quả

1	111111111	5, 6, 7, 8, 9	5	Positive
2	101001000	2, 4, 6	3	Negative
3	000000000	1, 2, 3, 4	4	Negative
4	111000001	4, 9	2	Negative
5	111100111	7, 8, 9	3	Positive
6	111101000	6	1	Positive
7	111100110	7, 8	2	Positive
8	111100000	không có	0	Positive
9	111100000	không có	0	Positive
10	000000000	1, 2, 3, 4	4	Negative

Sắp xếp tăng dần: ID 8 và 9 (d = 0), ID 6 (d = 1), ID 4 và 7 (d = 2), ID 2 và 5 (d = 3), ID 3 và 10 (d = 4), ID 1 (d = 5).

3. Áp dụng k-NN với k = 3

Ba láng giềng gần nhất là ID 8, 9, 6 đều Positive nên bỏ phiếu 3 Positive, 0 Negative. Kết luận bệnh nhân là **Positive**.

4. Thay đổi giá trị k

k = 1: ID 8 (Positive) nên kết quả Positive.

k = 5: thêm ID 4 (Negative) và ID 7 (Positive) vì cùng d = 2, được 4 Positive, 1 Negative nên Positive.

k = 7: thêm ID 2 (Negative) và ID 5 (Positive) vì cùng d = 3, được 5 Positive, 2 Negative nên Positive.

Nhận xét: kết quả Positive với mọi k. Khi k tăng thì số láng giềng Negative xuất hiện nhiều hơn (từ 0 lên 2) nên độ chắc chắn giảm, nếu k quá lớn thì sẽ lấy cả các mẫu ở xa và có thể đổi kết quả. k = 1 thì dễ bị ảnh hưởng bởi một mẫu lạ.

5. k-NN có trọng số

Ba láng giềng gần nhất là ID 8 (d = 0), ID 9 (d = 0) và ID 6 (d = 1). Công thức w = 1/d không xác định tại d = 0. Quy ước khi có láng giềng trùng khớp chính xác là chỉ xét các mẫu có d = 0; nếu có nhiều mẫu như vậy thì chia đều trọng số cho chúng.

ID 8 và ID 9 cùng có khoảng cách 0 nên mỗi mẫu nhận trọng số chuẩn hóa 0.5; ID 6 có khoảng cách lớn hơn nên không ảnh hưởng theo quy ước này.

Trọng số chuẩn hóa: ID 8 = 0.5; ID 9 = 0.5; ID 6 = 0.

Tổng trọng số Positive = 0.5 + 0.5 = 1.0; Negative = 0.

Kết quả dự đoán là **Positive**, giống bỏ phiếu thông thường.

6. Phân tích dữ liệu

Có 6 ca Positive (ID 1, 5, 6, 7, 8, 9) và 4 ca Negative (ID 2, 3, 4, 10). Số ca có từng triệu chứng:

Triệu chứng	Positive (trên 6)	Negative (trên 4)
Sốt	6	2
Ho khan	6	1
Mệt mỏi	6	2
Đau họng	6	0
Tiêu chảy	1	0
Đau đầu	2	1
Mất vị giác/khứu giác	3	0
Khó thở	3	0
Đau ngực	2	1

Triệu chứng xuất hiện nhiều nhất ở ca Positive: sốt, ho khan, mệt mỏi, đau họng đều có ở cả 6 ca. Trong đó đau họng không có ở ca Negative nào nên phân biệt tốt nhất.

Triệu chứng ít xuất hiện nhất: tiêu chảy, chỉ có ở 1 ca (ID 1).

Triệu chứng có thể gây nhiễu: đau đầu và đau ngực vì xuất hiện ở cả hai nhóm với tỉ lệ gần nhau (2/6 so với 1/4), nên không giúp phân biệt rõ.

Dữ liệu y tế hợp với k-NN vì những bệnh nhân có triệu chứng giống nhau thường có cùng kết quả xét nghiệm.

7. Câu hỏi tư duy

1. Với 100 triệu bệnh nhân, mỗi lần dự đoán phải tính khoảng cách tới cả 100 triệu mẫu và phải giữ toàn bộ dữ liệu trong bộ nhớ nên rất chậm và tốn. Có thể dùng cây KD, cây Ball hoặc tìm láng giềng gần đúng để giảm thời gian.

2. k-NN gọi là học lười vì lúc huấn luyện chỉ lưu dữ liệu, chưa xây mô hình nào. Đến khi có mẫu mới mới bắt đầu tính toán.

3. Dữ liệu nhị phân nên dùng Hamming vì nó đếm đúng số triệu chứng khác nhau, dễ hiểu. Euclid cũng tính được nhưng nó chỉ là căn bậc hai của khoảng cách Hamming nên thứ tự gần xa không đổi, không có thêm lợi ích gì.

4. Có bị ảnh hưởng. Lớp có nhiều mẫu hơn dễ chiếm đa số trong k láng giềng nên kết quả bị lệch về lớp đó. Có thể xử lý bằng cách dùng trọng số theo khoảng cách, tăng thêm mẫu cho lớp ít hoặc bớt mẫu lớp nhiều.

PHẦN 4. HỌC LUẬT (PRISM VÀ FOIL)

Câu 1. Thuật toán PRISM với dữ liệu tuyển dụng

Quy ước chọn: chọn cặp thuộc tính–giá trị có accuracy P(lớp | cặp) cao nhất, nếu hòa thì chọn cặp bao phủ nhiều mẫu hơn, nếu vẫn hòa thì lấy cặp đứng trước. Viết tắt: PK = Practical Knowledge, Comm = Communication Skills.

a) Lớp Job Offer = Yes (7 mẫu: 1, 2, 5, 6, 8, 9, 10)

Lần 1 (tập U gồm 10 mẫu), accuracy = số mẫu Yes / số mẫu thỏa cặp:

Cặp	Accuracy	Cặp	Accuracy
CGPA ≥ 9	3/4	PK = Very good	2/2
CGPA ≥ 8	4/4	PK = Good	4/5
CGPA < 8	0/2	PK = Average	1/3
Interactiveness = Yes	5/6	Comm = Good	4/5
Interactiveness = No	2/4	Comm = Moderate	3/3
		Comm = Poor	0/2

Có ba cặp đạt 100%: CGPA ≥ 8 (bao phủ 4 mẫu), PK = Very good (2 mẫu), Comm = Moderate (3 mẫu). Chọn CGPA ≥ 8 vì bao phủ nhiều nhất. Luật R1: Nếu CGPA ≥ 8 thì Job Offer = Yes. Luật này phủ các mẫu 2, 5, 9, 10 (toàn Yes) nên loại bỏ 4 mẫu này khỏi U.

Lần 2 (U còn mẫu 1, 3, 4, 6, 7, 8; trong đó Yes là 1, 6, 8):

CGPA ≥ 9: 3/4; CGPA < 8: 0/2; Interactiveness = Yes: 2/3; Interactiveness = No: 1/3; PK = Very good: 2/2; PK = Good: 1/2; PK = Average: 0/2; Comm = Good: 2/3; Comm = Moderate: 1/1; Comm = Poor: 0/2.

Hai cặp đạt 100% là PK = Very good (2 mẫu) và Comm = Moderate (1 mẫu), chọn PK = Very good. Luật R2: Nếu Practical Knowledge = Very good thì Job Offer = Yes. Loại bỏ mẫu 1 và 8.

Lần 3 (U còn mẫu 3, 4, 6, 7; Yes chỉ còn mẫu 6):

CGPA ≥ 9: 1/2; Interactiveness = Yes: 1/2; PK = Good: 1/2; Comm = Moderate: 1/1; các cặp còn lại 0.

Chọn Comm = Moderate (100%). Luật R3: Nếu Communication Skills = Moderate thì Job Offer = Yes. Hết mẫu Yes nên dừng.

Bộ luật cho Yes:

R1: Nếu CGPA ≥ 8 thì Job Offer = Yes

R2: Nếu Practical Knowledge = Very good thì Job Offer = Yes

R3: Nếu Communication Skills = Moderate thì Job Offer = Yes

b) Lớp Job Offer = No (3 mẫu: 3, 4, 7)

Lần 1 (U gồm 10 mẫu), accuracy = số mẫu No / số mẫu thỏa cặp:

Cặp	Accuracy	Cặp	Accuracy

CGPA ≥ 9	1/4	PK = Very good	0/2
CGPA ≥ 8	0/4	PK = Good	1/5
CGPA < 8	2/2	PK = Average	2/3
Interactiveness = Yes	1/6	Comm = Good	1/5
Interactiveness = No	2/4	Comm = Moderate	0/3
		Comm = Poor	2/2

CGPA < 8 và Comm = Poor cùng 2/2 và cùng bao phủ 2 mẫu, chọn CGPA < 8 vì đứng trước. Luật R1: Nếu CGPA < 8 thì Job Offer = No. Loại bỏ mẫu 4 và 7.

Lần 2 (U còn 8 mẫu: 1, 2, 3, 5, 6, 8, 9, 10; No chỉ còn mẫu 3): Comm = Poor có 1/1 (chỉ mẫu 3), PK = Average 1/2, Interactiveness = No 1/3, CGPA ≥ 9 1/4. Chọn Comm = Poor. Luật R2: Nếu Communication Skills = Poor thì Job Offer = No. Hết mẫu No nên dừng.

Bộ luật cho No:

R1: Nếu CGPA < 8 thì Job Offer = No

R2: Nếu Communication Skills = Poor thì Job Offer = No

Câu 2. PRISM với dữ liệu kết quả học tập

Có 6 mẫu Pass (1, 3, 5, 6, 7, 10) và 4 mẫu Fail (2, 4, 8, 9). Viết tắt: Att = Attendance, Assign = Assignment, Proj = Project Submitted, Comm = Communication Skill.

a) Luật cho Result = Pass

Khởi tạo: Rule-Set rỗng, U = toàn bộ 10 mẫu.

Lần 1: accuracy P(Pass | cặp) trên 10 mẫu

Cặp	Accuracy	Cặp	Accuracy
Att = Good	5/5	Proj = Yes	5/6
Att = Average	1/3	Proj = No	1/4
Att = Poor	0/2	Comm = Good	4/5
Assign = Yes	3/5	Comm = Poor	0/3
Assign = No	3/5	Comm = Fair	2/2

Có hai cặp đạt 100%: Att = Good (5 mẫu) và Comm = Fair (2 mẫu), chọn Att = Good vì phủ nhiều hơn. Luật R1: Nếu Attendance = Good thì Result = Pass. Luật phủ các mẫu 1, 3, 5, 7, 10 (toàn Pass) nên loại bỏ khỏi U.

Lần 2 (U còn mẫu 2, 4, 6, 8, 9; Pass chỉ còn mẫu 6):

Att = Average 1/3; Att = Poor 0/2; Assign = Yes 0/2; Assign = No 1/3; Proj = Yes 1/2; Proj = No 0/3; Comm = Good 1/2; Comm = Poor 0/3.

Trong U còn lại, Communication Skill = Good chỉ phủ mẫu 6 và mẫu này thuộc Pass, nên accuracy = 1/1 = 1.0. Đây là cặp có accuracy cao nhất; luật R2: Nếu Communication Skill = Good thì Result = Pass. Luật phủ mẫu 6. Không còn mẫu Pass chưa được phủ nên dừng.

b) Luật cho Result = Fail

Lần 1: accuracy P(Fail | cặp) trên 10 mẫu

Cặp	Accuracy	Cặp	Accuracy
Att = Good	0/5	Proj = Yes	1/6
Att = Average	2/3	Proj = No	3/4
Att = Poor	2/2	Comm = Good	1/5
Assign = Yes	2/5	Comm = Poor	3/3
Assign = No	2/5	Comm = Fair	0/2

Comm = Poor và Att = Poor đạt 100%, chọn Comm = Poor vì phủ 3 mẫu (2, 4, 9). Luật R3: Nếu Communication Skill = Poor thì Result = Fail. Loại bỏ mẫu 2, 4, 9.

Lần 2 (U còn mẫu 1, 3, 5, 6, 7, 8, 10; Fail chỉ còn mẫu 8): Att = Poor 1/1, Proj = Yes 1/6, Assign = Yes 1/4, Comm = Good 1/5. Chọn Att = Poor. Luật R4: Nếu Attendance = Poor thì Result = Fail. Hết mẫu Fail nên dừng.

c) Rule Set cuối cùng

R1: Nếu Attendance = Good thì Result = Pass

R2: Nếu Communication Skill = Good thì Result = Pass

R3: Nếu Communication Skill = Poor thì Result = Fail

R4: Nếu Attendance = Poor thì Result = Fail

d) Coverage và Accuracy

Coverage = số mẫu thỏa vế điều kiện / 10; Accuracy = số mẫu thỏa cả điều kiện và kết luận / số mẫu thỏa điều kiện (tính trên cả 10 mẫu).

Luật	Mẫu được phủ	Coverage	Accuracy
R1	1, 3, 5, 7, 10	5/10 = 0.5	5/5 = 1.0
R2	1, 3, 6	3/10 = 0.3	3/3 = 1.0
R3	2, 4, 9	3/10 = 0.3	3/3 = 1.0
R4	4, 8	2/10 = 0.2	2/2 = 1.0

e) Conflict Resolution

Xung đột xảy ra khi một mẫu thỏa nhiều luật nhưng các luật cho kết luận khác nhau. Ví dụ học sinh có Attendance = Good (thỏa R1, kết luận Pass) nhưng Communication Skill = Poor (thỏa R3, kết luận Fail). Cách xử lý:

Rule ordering: sắp các luật theo thứ tự cố định và dùng luật đầu tiên thỏa mãn.

Priority list: gán độ ưu tiên cho từng luật (theo kinh nghiệm hoặc tầm quan trọng của lớp) và chọn luật có ưu tiên cao nhất.

Accuracy ordering: chọn luật có accuracy cao nhất; nếu bằng nhau thì chọn luật có coverage lớn hơn (ví dụ ở đây R1 có coverage 0.5 lớn hơn R3 nên chọn Pass).

f) Câu hỏi mở rộng

1. PRISM thuộc loại rule-oriented, vì thuật toán học từng luật cho từng lớp mục tiêu, không chọn thuộc tính để chia cả tập như cây quyết định.

2. ID3 chia dữ liệu theo từng thuộc tính tạo thành một cây hoàn chỉnh (một phân hoạch), còn PRISM học từng luật riêng cho một lớp, bỏ các mẫu đã phủ rồi học tiếp. Vì vậy các luật của PRISM có thể chồng lấn lên nhau.

3. PRISM thuộc nhóm phủ tuần tự vì học một luật, loại các mẫu dương được luật đó phủ, rồi lặp lại cho đến khi hết mẫu của lớp cần học.

Câu 3. FOIL-Gain và sinh luật

Công thức: FOIL-Gain = p × [log2(p /(p + n)) − log2(p /(p + n))], trong đó p, n là số mẫu dương, âm được luật bao phủ (chỉ số 0 là trước khi thêm literal, chỉ số 1 là sau khi thêm).

a) Mẫu dương và mẫu âm

Lớp cần học là Job Offer = Yes. Mẫu dương: 1 và 2, nên P = 2. Mẫu âm: 3, 4, 5, nên N = 3. Luật rỗng bao phủ tất cả nên p = 2, n = 3 và log2(p /(p + n)) = log2(0.4) = −1.3219.

b) FOIL-Gain vòng 1

Literal	p	n	FOIL-Gain
CGPA = ≥9 (mẫu 1, 3)	1	1	1×(−1 + 1.3219) = 0.3219
CGPA = ≥8 (mẫu 5)	0	1	0
CGPA = <8 (mẫu 2, 4)	1	1	1×(−1 + 1.3219) = 0.3219
Interactiveness = Yes (mẫu 1, 2, 3, 5)	2	2	2×(−1 + 1.3219) = 0.6439
Interactiveness = No (mẫu 4)	0	1	0
Practical Knowledge = Good (mẫu 1, 2, 4, 5)	2	2	2×(−1 + 1.3219) = 0.6439
Practical Knowledge = Average (mẫu 3)	0	1	0

Literal có p = 0 không phủ mẫu dương nào nên gain bằng 0. Hai literal Interactiveness = Yes và Practical Knowledge = Good cùng đạt 0.6439, mình chọn Interactiveness = Yes (đứng trước).

c) Cập nhật luật sau vòng 1

newR = Job Offer ← Interactiveness = Yes. Luật này phủ mẫu 1, 2 (dương) và 3, 5 (âm), nên p = 2, n = 2. Mẫu 4 (Interactiveness = No) bị loại khỏi tập mẫu âm.

d) FOIL-Gain vòng 2

Trên tập còn lại (mẫu 1, 2, 3, 5), log2(p /(p + n)) = log2(0.5) = −1:

Literal	p	n	FOIL-Gain
CGPA = ≥9 (mẫu 1, 3)	1	1	1×(−1 + 1) = 0
CGPA = ≥8 (mẫu 5)	0	1	0
CGPA = <8 (mẫu 2)	1	0	1×(0 + 1) = 1
Practical Knowledge = Good (mẫu 1, 2, 5)	2	1	2×(−0.5850 + 1) = 0.8301
Practical Knowledge = Average (mẫu 3)	0	1	0

Chọn CGPA = <8 (FOIL-Gain = 1). Luật mới: Job Offer ← Interactiveness = Yes AND CGPA = <8, phủ mẫu 2 (dương) và không phủ mẫu âm nào nên đã thuần nhất.

e) Luật cuối cùng

Luật 1: Nếu Interactiveness = Yes và CGPA < 8 thì Job Offer = Yes. Luật này chỉ phủ mẫu 2, mẫu dương 1 chưa được phủ nên FOIL sinh thêm một luật nữa trên các mẫu còn lại (1, 3, 4, 5): p = 1, n = 3. Vòng 1 chọn CGPA = ≥9 (p = 1, n = 1, FOIL-Gain = 1×(−1 + 2) = 1.0 là lớn nhất, trong khi Interactiveness = Yes và Practical Knowledge = Good chỉ được 0.415). Vòng 2 trên mẫu 1, 3, chọn Practical Knowledge = Good (p = 1, n = 0, FOIL-Gain = 1.0).

Bộ luật FOIL học được:

Luật 1: Nếu Interactiveness = Yes và CGPA < 8 thì Job Offer = Yes

Luật 2: Nếu CGPA ≥ 9 và Practical Knowledge = Good thì Job Offer = Yes